O1MBID Fundamentos de la tecnología Big Data



Universidad Internacional de Valencia

Sesión 3
Tema 2 + Actividad





- Agenda
 - Dudas
 - Tema 2 2de2: Fuentes de datos en entornos Big data
 - Actividad



- Agenda
 - Dudas
 - Tema 2 2de2: Fuentes de datos en entornos Big data
 - Actividad


















- Agenda
 - Dudas
 - Tema 2 2de2: Fuentes de datos en entornos Big data
 - Actividad



> Fuentes de datos en entornos Big data

- 1) ¿Qué es una fuentes de datos?
- 2) Diferencias respecto a las tecnologías de datos tradicionales
- 3) Tipos de datos y flujo de datos
- 4) Calidad de Datos
- 5) Las V's del Big Data




> Tipos de datos y flujos de datos

- Estructurados
 - formato + finitos
 - ejemplo, expediente académico
- No Estructurados
 - sin formato + indeterminado + herramientas especificas
 - ejemplo, video
- Semiestructurados
 - marcadores o organización interna
 - ejemplo, XML



> Tipos de datos y flujos de datos

Ejemplo:





> Fuentes de datos en entornos Big data

- 1) ¿Qué es una fuentes de datos?
- 2) Diferencias respecto a las tecnologías de datos tradicionales
- 3) Tipos de datos y flujo de datos
- 4) Calidad de Datos
- 5) Las V's del Big Data



Calidad de datos

ISO 25012:2008

Grado en que las características de los datos satisfacen las necesidades explícitas e implícitas cuando se usan bajo condiciones específicas.

"Calidad adecuación al uso"



Calidad de datos

Importancia en Big Data

- Objetivo: definir para qué y por qué se quieren los datos.
 ¿Qué valor me aporta?
- **Dimensiones de Calidad**: disponibilidad, usabilidad, confiabilidad, pertinencia y presentación.



Calidad de datos

Importancia en Big Data

Condición previa para el análisis y el uso de Big Data y para garantizar el valor de esos datos.



- Calidad de datos
 - Disponibilidad
 - Usabilidad
 - Confiabilidad
 - Pertinencia
 - Presentación



Disponibilidad

Accesibilidad:

- Interfaz de acceso a datos
- Los datos públicos o fáciles de adquirir

Oportunidad:

- Rango de tiempo, para que sean útiles
- Actualizados "regularmente"
- Intervalo de tiempo entre la recopilación, procesamiento y uso cumple los requisitos



Usabilidad

Credibilidad:

- Fuente de los datos: organizaciones especializadas de un país, campo o industria
- Expertos o especialistas auditan regularmente y comprueban la exactitud de los datos
- Los datos existen en el rango de valores conocidos o "aceptables"



Confiabilidad

Exactitud:

- Los datos proporcionados son precisos
- La representación de datos (o valor) refleja bien el estado real de la información de origen
- La representación de información (datos) no causara ambigüedad

Consistencia:

- Después de procesar los datos, sus conceptos, dominios de valor y formatos coinciden con los originales
- Durante un cierto tiempo, los datos permanecen consistentes
- Durante un cierto tiempo, los datos permanecen verificables



Confiabilidad

Integridad:

- El formato de los datos es claro y cumple los criterios
- Los datos son consistentes con la integridad estructural
- Los datos son consistentes con la integridad del contenido

Completitud:

- Si una deficiencia de un componente afectara el uso de los datos para datos con componentes múltiples
- Si una deficiencia de un componente afectara la precisión y la integridad de los datos



Pertinencia

Conveniencia:

- Los datos recogidos no coinciden completamente con el tema, pero exponen un aspecto parcial del mismo.
- La mayoría de los conjuntos de datos recuperados están dentro de la temática de recuperación que los usuarios necesitan
- La temática de la información proporciona coincidencias con la temática de recuperación de los usuarios



Presentación

Legibilidad:

- Los datos (contenido, formato, etc.) son claros y comprensibles
- Es fácil juzgar que los datos facilitados satisfacen las necesidades
- La descripción de los datos, la clasificación y el contenido de codificación satisfacen la especificación y son fáciles de entender




> Fuentes de datos en entornos Big data

- 1) ¿Qué es una fuentes de datos?
- 2) Diferencias respecto a las tecnologías de datos tradicionales
- 3) Tipos de datos y flujo de datos
- 4) Calidad de Datos
- 5) Las V's del Big Data




Las V's del Big Data










^{*} https://www.elderresearch.com/blog/42-v-of-big-data








^{*} https://www.researchgate.net/publication/335619326_Unlock_Different_V's_of_Big_Data_for_Analytics



Las V's del Big Data





Infografía Big Data: las 7 V

http://www.iic.uam.es/innovacion/big-data-infografia-7-v/https://www.youtube.com/watch?v=S81frJYbjcE

Big Data Technology with 8 V's

https://www.m-brain.com/technology/

The 10 Vs of Big Data

https://tdwi.org/articles/2017/02/08/10-vs-of-big-data.aspx



Las siete 'V' del Big Data

https://bbvaopen4u.com/es/actualidad/las-siete-v-del-big-data

The 42 V's of Big Data and Data Science

* https://www.elderresearch.com/blog/42-v-of-big-data https://www.kdnuggets.com/2017/04/42-vs-big-data-data-science.html

Las 10 V's del Big Data

https://www.grupo-novatech.com/las-10-vs-del-big-data/

How to Ensure the Validity, Veracity, and Volatility of Big Data

https://www.dummies.com/programming/big-data/engineering/how-to-ensure-the-validity-veracity-and-volatility-of-big-data/



The Eight V's of Supercomputing and Big Data

https://www.nimbix.net/eight-vs-supercomputing-big-data

BIG DATA AND FIVE V'S CHARACTERISTICS

https://www.researchgate.net/publication/332230305_BIG_DATA_AND_FIVE_V'S_CHARACTERISTICS

Big Data: el futuro a través de los datos

http://www.upm.es/sfs/Rectorado/Gabinete%20del%20Rector/Revista%20UPM/NUMERO 31 VER.pdf

Los Big Data: Conceptos relacionados y algunas aplicaciones en pediatría

https://scielo.conicyt.cl/scielo.php?script=sci_arttext&pid=S0370-41062019000400376#B13



Grandes datos, grandes desafíos para las ciencias sociales

http://www.scielo.org.mx/scielo.php?pid=S0188-25032018000200415&script=sci arttext

The 23Vs of Big Data

https://hackernoon.com/the-23vs-of-big-data-c9146716e0cb

The five V's of big data

https://www.bbva.com/en/five-vs-big-data/

¿Cuáles son las 5 V's del Big Data?

https://www.iebschool.com/blog/5-vs-del-big-data/



WHAT ARE THE 7 V'S OF BIG DATA?

https://www.yourtechdiet.com/blogs/7vs-big-data/

LAS 10 V'S DEL BIG DATA

https://www.datahack.es/blog/big-data/10-vs-del-big-data/

•••









- Agenda
 - Dudas
 - Tema 2 2de2: Fuentes de datos en entornos Big data
 - Actividad




> Actividad

MongoDB + Python + JSON













Conceptos clave

- -MongoDB
- -JSON









- SGBD Orientada a documentos
- Maneja "colecciones" similares a tablas



MongoDB

Documento

```
name: "sue",
                                          field: value
                                          field: value
age: 26,
status: "A",
                                          field: value
groups: [ "news", "sports" ]
                                          field: value
```



>

MongoDB

Colección

```
na
      na
      ag
            name: "al",
      st
            age: 18,
            status: "D",
            groups: [ "politics", "news" ]
```

Conjunto de documentos no necesariamente con la misma estructura



>

MongoDB

Modelo Relacional	MongoDB
Tabla	Colección
registro	documento
columna	campo

https://www.mongodb.com/docs/manual/reference/sql-comparison/#sql-to-mongodb-mapping-chart



MongoDB

- ☐ MongoDB almacena internamente los datos en BSON, abreviatura de Binary-JSON.
- ☐ JSON es Java Script Object Notation, una notación estándar para el intercambio de datos.
- ☐ JSON especifica una gramática mediante expresiones regulares.






MongoDB JSON


```
value:=
   String |
   number 1
   object
   array |
   true |
   false I
   null
```




JSON











Diccionario Python = JSON



```
{"Space X":
 {"VehiculosLanzamiento":
  {"Nombre": "Falcon 1", "CargaUtil": 670},
  {"Nombre":"Falcon 9","CargaUtil":22800},
  {"Nombre": "Falcon Heavy", "CargaUtil": 63800}
 {"Naves":
  {"Nombre": "Dragon 1", "Descripcion": "Cargo Dragon"},
  {"Nombre":"Dragon 2","Descripcion":"Crew Dragon"}
```

```
"Space X": [
           "VehiculosLanzamiento": [
               "Nombre": "Falcon 1",
               "CargaUtil": 670
               "Nombre": "Falcon 9",
10
               "CargaUtil": 22800
11
12
13 -
               "Nombre": "Falcon Heavy",
14
               "CargaUtil": 63800
15
16
17
18
19 -
          "Naves":
20 -
21 -
22
               "Nombre": "Dragon 1",
               "Descripcion": "Cargo Dragon"
24
25 -
26
               "Nombre": "Dragon 2",
27
               "Descripcion": "Crew Dragon"
28
29
30
```



MongoDB - Twitter

```
{ id:POST ID,
                                               Los tags se integran como
title:TITLE OF POST,
                                               array.
description:POST DESCRIPTION,
by:POST BY,
url:URL OF POST
                                              Los comentarios se integran
tags:[TAG1,TAG2,TAG3],
                                              como array de subdocumentos
likes:TOTAL LIKES,
comments:
{user:'COMMENT BY', message:TEXT, dateCreated:DATE TIME, like:LIKES},
{user:'COMMENT BY',message:TEXT,dateCreated:DATE TIME,like:LIKES}
```



MongoDB Consultas + Actualizaciones



Equivalencias de SQL en MongoDB

https://www.mongodb.com/docs/manual/reference/sql-comparison/#sql-to-mongodb-mapping-chart

SQL Terms, Functions, and Concepts	MongoDB Aggregation Operators
WHERE	<u>\$match</u>
GROUP BY	\$group
HAVING	<u>\$match</u>
SELECT	\$project
ORDER BY	\$sort
LIMIT	<u>\$limit</u>
SUM()	<u>\$sum</u>
COUNT()	<u>\$sum</u>
join	No existe, se puede hacer algo similar con <u>\$unwind</u> con los campos embebidos en un subdocumento.



MongoDB CRUD Operations

https://docs.mongodb.com/manual/crud/

find

count

sort

group

sum

unwind

limit



https://docs.mongodb.com/manual/core/aggregation-pipeline/




```
Collection
db.orders.aggregate( [
                        { $match: { status: "A" } },
                        { $group: { _id: "$cust_id",total: {$sum: "$amount" } } }
          cust id: "A123",
          amount: 500,
          status: "A"
          cust id: "A123",
          amount: 250,
          status: "A"
          cust id: "B212",
          amount: 200,
          status: "A"
```



```
Collection
db.orders.aggregate( [
  $match stage \rightarrow { $match: { status: "A" } },
                         { $group: { _id: "$cust_id",total: {$sum: "$amount" } } }
     cust id: "A123",
     amount: 500,
     status: "A"
                                          cust id: "A123",
                                          amount: 500,
                                          status: "A"
     cust id: "A123",
     amount: 250,
    status: "A"
                                          cust id: "A123",
                                          amount: 250,
                        $match
                                          status: "A"
     cust id: "B212",
     amount: 200,
     status: "A"
                                          cust id: "B212",
                                          amount: 200,
                                          status: "A"
     cust_id: "A123",
     amount: 300,
     status: "D"
```







```
Collection
db.orders.aggregate( [
  $match stage \rightarrow { $match: { status: "A" } },
  $group stage \(\bigsim\) { $group: { _id: "$cust_id",total: {$sum: "$amount" } } }
                          ])
     cust id: "A123",
     amount: 500,
     status: "A"
                                          cust_id: "A123",
                                          amount: 500,
                                          status: "A"
     cust id: "A123",
                                                                                  id: "A123",
     amount: 250,
                                                                                  total: 750
     status: "A"
                                          cust id: "A123",
                                          amount: 250,
                        $match
                                                              $group
                                          status: "A"
     cust_id: "B212",
                                                                                  id: "B212",
     amount: 200,
                                                                                  total: 200
     status: "A"
                                          cust id: "B212",
                                          amount: 200,
                                          status: "A"
     cust id: "A123",
     amount: 300,
     status: "D"
```

\$sort

, {\$sort : {total : 1}}



```
db.orders.aggregate([{$match: {status: "A"}}, {$group: {_id: "$cust_id", total: {$sum: "$amount"}}}, {$sort: {total: 1}}])
```

```
"total" : 200
"total" : 750
```



\$unwind desagregar arrays, por cada elemento del array crea un nuevo documento duplicando los demás datos.

```
/* 1 */
                                                    /* 3 */
  " id" : ObjectId("5eaa6b2f804aacfaf16311ce"),
                                                      " id": ObjectId("5eaa6b95804aacfaf163286d"),
  "nombre": "roger",
                                                      "nombre": "monica",
  "deportes": [ "rally", "basquet"]
                                                       "deportes": ["basquet", "zumba"]
                                                    /* 4 */
/* 2 */
  " id": ObjectId("5eaa6b5d804aacfaf1631bce"),
                                                      " id": ObjectId("5eaa6bb7804aacfaf1632ffd"),
  "nombre": "jordi",
                                                      "nombre": "jony",
  "deportes" : [ "egames" ]
                                                      "deportes": ["futbol", "egames"]
```



db.getCollection('deportesPreferidos').aggregate([{\$unwind: "\$deportes"}])

	deportesPreferidos 0.123 sec.				
	_id	nombre	deportes		
1	ObjectId("5	"" roger	"" rally		
2	ObjectId("5	"" roger	"" basquet		
3	ObjectId("5	"" jordi	"" egames		
4	ObjectId("5	"" monica	"" basquet		
5	ObjectId("5	"" monica	"" zumba		
6	ObjectId("5	"" jony	"" futbol		
7	ObjectId("5	iii jony	egames		



db.getCollection('deportesPreferidos').aggregate([{\$unwind: "\$deportes"}, {\$group: {_id:"\$deportes", total: {\$sum:1}}}])





Actualizar: Query Selectors

Name	Description
\$eq	Matches values that are equal to a specified value.
\$gt	Matches values that are greater than a specified value.
\$gte	Matches values that are greater than or equal to a specified value.
\$in	Matches any of the values specified in an array.
\$lt	Matches values that are less than a specified value.
\$lte	Matches values that are less than or equal to a specified value.
\$ne	Matches all values that are not equal to a specified value.
\$nin	Matches none of the values specified in an array.



Actualizar

\$set cambia valor
 db.Partidos.update({siglas:{\$eq:"PSOE"}},{\$set:{programa:"Blabla"}})
 □ \$push: añade un valor especificado a un array.
 db.Partidos.update({ id:1}, {\$push:{votos:89}})

https://docs.mongodb.com/manual/reference/method/db.collection.update/
https://docs.mongodb.com/manual/reference/operator/query/#query-selectors



Buscar

db.collection.find(<criteria>, , /projection>)

db.Partidos.find({siglas:{\$eq:"PSOE"}}, {nombr(:1}))

Projection = nombre atributo y booleano (1 mostrar y 0 no mostrar, lista blanca o lista negra)

https://docs.mongodb.com/manual/reference/method/db.collection.find/ https://docs.mongodb.com/manual/reference/method/db.collection.find/#find-projection



Buscar – Operadores Lógicos

- \$all: Devuelve cierto si el array almacenado como valor del atributo tiene los mismos elementos que el proporcionado en la condición.
- \$exists: Para comprobar que el atributo existe en el documento.
- \$mod: Para comprobar el resto de una división del valor del atributo por un número.
- \$ne: Devuelve cierto si no es igual (non equal)
- \$in: Devuelve cierto si el valor está entre alguno de los proporcionados.
- \$nin: Contrario de \$in.
- \$or: Para indicar que se debe cumplir al menos una condición de entre un grupo de condiciones.
- \$nor: Contrario de \$or.
- \$size: Devuelve true si coincide con el número de elementos de un array.
- \$type: Para comprobar el tipo del valor almacenado (número, cadena...)



Consulta agregados

db.collection.aggregate(pipeline)


- \$first, \$last, \$min, \$max, \$avg, \$sum,
- \$push o \$addtoSet para generar un array con los valores que devuelve, etc.
- \$group: indica el atributo por el que se quiere agregar
- \$match: criterio a cumplir



Consulta agregados

db.collection.aggregate(pipeline)

db.Partidos.aggregate([{\$group:{_id:"\$tendencia", "num":{"\$sum":1}}}])





> Dudas



MongoDB Atlas https://www.mongodb.com/

MONGODB ATLAS

MongoDB Atlas. MongoDB totalmente gestionada en la nube.

Aproveche el poder de sus datos creando y administrando sus datos en la nube.



Registrarse

Vea de forma gratuita lo que Atlas es capaz de hacer



Nombre* Roger

Apellido* Clotet

Correo Electrónico*

Contraseña*

Acepto las Terms of Service y la Privacy Policy.



CONFIGURACIÓN





Great, now verify your email



Check your inbox at rclotetm@unemi.edu.ec and click the verification link inside to complete your registration. This link will expire shortly, so verify soon!

Don't see an email? Check your spam folder.

Link expired? Resend verification email

Email successfully verified!







Enable your multi-factor authentication methods

Secure your account across MongoDB

Secure your MongoDB account across MongoDB Atlas, University, Community, and Support with Multi-Factor-Authentication (MFA). Setting up MFA will help reduce risks from outside threats to your account. Learn More

Setup Backup MFA Methods

In addition, you will also be setting up an additional method in this setup. This is a precaution in the case you lose access to your first MFA enabled device and to avoid being locked out.




MongoDB.

Multi-factor authentication setup is now complete

Your MFA methods have now been enabled. You can always add or remove more methods under your Account Application inside of the Security page. Multi-factor authentication (MFA) methods In the case that you lose access to your first enabled MFA method, set up another one to avoid being looked out. Learn more 6 Email Okta Verify Mobile App Security Key/Biometric SETUP Authenticator App SETUP SETUP Why is this important for me? MFA will enhance your account's security by requiring you to identify yourself by more than your email and password. Learn how this protects your account &



Overview





Deploy your cluster

Use a template below or set up advanced configuration options. You can also edit these configuration options once the cluster is created.










Go to Advanced Configuration


Create Deployment




Where would you like to connect from? Enable access for any network(s) that need to read and write data to your cluster. ADVANCED My Local Environment **Cloud Environment** Use this to add network IP addresses to Use this to configure network access the IP Access List. This can be modified at between Atlas and your cloud or onany time. premise environment. Specifically, set up IP Access Lists, Network Peering, and Private Endpoints. i We added your current IP address. You can connect to your cluster locally from this device. Add entries to your IP Access List Only an IP address you add to your Access List will be able to connect to your project's clusters. You can manage existing IP entries via the Network Access Page. IP Address Description Add My Current IP Address Add Entry **IP Access List** Description ✓ EDIT
☐ REMOVE 0.0.0.0/0 All



Overview







TOOLS


MongoDB Command Line Database Tools Download

The MongoDB Database Tools are a collection of command-line utilities for working with a MongoDB deployment. These tools release independently from the MongoDB Server schedule enabling you to receive more frequent updates and leverage new features as soon as they are available. See the MongoDB Database Tools documentation for more information.



https://www.mongodb.com/try/download/database-tools

Mongoimport



Mongoimport

mongoimport "mongodb+srv://cluster0.sit6c.mongodb.net/" --username rclotetm --password ????? --db VIU --collection tweets --file tweets_UNEMI_2.json --type json

mongoimport "mongodb+srv://cluster0.sit6c.mongodb.net/" --username rclotetm --password ????? --db VIU – collection **cuentas** --file cuentas UNEMI 2.json --type json

Mongoimport

```
mongoimport "mongodb+srv://cluster0.sit6c.mongodb.net/" --username rclotetm --password
                            connected to: mongodb+srv://cluster0.sit6c.mongodb.net/
2024-09-22T18:49:06.048-0500
                            [#.....] UNEMI.tweets 3.06MB/42.4MB (7.2%)
2024-09-22T18:49:09.051-0500
2024-09-22T18:49:12.050-0500
                            [###.....] UNEMI.tweets 6.75MB/42.4MB (15.9%)
                            [###............] UNEMI.tweets 6.75MB/42.4MB (15.9%)
2024-09-22T18:49:15.054-0500
2024-09-22T18:49:18.063-0500
                            [#######......] UNEMI.tweets 13.2MB/42.4MB (31.2%)
2024-09-22T18:49:21.060-0500
                            [##########.....] UNEMI.tweets 16.6MB/42.4MB (39.1%)
2024-09-22T18:49:24.060-0500
                            [#########.....] UNEMI.tweets 16.6MB/42.4MB (39.1%)
2024-09-22T18:49:27.052-0500
                            [###########.....] UNEMI.tweets 20.2MB/42.4MB (47.5%)
2024-09-22T18:49:30.063-0500
                            [############# (56.0%) UNEMI.tweets 23.8MB/42.4MB
2024-09-22T18:49:33.056-0500
2024-09-22T18:49:36.063-0500
                            [############### .....] UNEMI.tweets 26.6MB/42.4MB (62.9%)
2024-09-22T18:49:39.055-0500
                            [################ (71.5%)
                            [################## (71.5%)
2024-09-22T18:49:42.054-0500
2024-09-22T18:49:45.062-0500
                            [############################ .....] UNEMI.tweets 34.2MB/42.4MB (80.5%)
2024-09-22T18:49:48.056-0500
                            [################### .....] UNEMI.tweets 34.2MB/42.4MB (80.5%)
                            [################################# ...] UNEMI.tweets 38.9MB/42.4MB (91.6%)
2024-09-22T18:49:51.051-0500
2024-09-22T18:49:54.049-0500
                            [####################### ] UNEMI.tweets 42.4MB/42.4MB (100.0%)
2024-09-22T18:49:57.053-0500
                            [####################### UNEMI.tweets 42.4MB/42.4MB (100.0%)
                            [####################### UNEMI.tweets 42.4MB/42.4MB (100.0%)
2024-09-22T18:49:58.483-0500
2024-09-22T18:49:58.483-0500
                            11991 document(s) imported successfully. 0 document(s) failed to import.
```

Compass. The GUI for MongoDB.




Trabaje fácilmente en con sus datos en Compass, la interfaz gráfica de usuario desarrollado por y para MongoDB. Compass proporciona de todo, desde el análisis de esquemas hasta la optimización de índices y pipelines de agregación en una única interfaz centralizada.

- Compass está disponible gratuitamente para descargar y usar
- Disponible en Linux, Mac o Windows

Compass. The GUI for MongoDB.

https://www.mongodb.com/try/download/compass



Access your data through tools





2. Copy the connection string, then open MongoDB Compass

Use this connection string in your application

mongodb+srv://rclotetm:<db_password>@cluster0.sit6c.mongodb.net/







Tweet Object

https://developer.x.com/en/docs/x-api/v1/data-dictionary/object-model/tweet

Visor JSON de un documento (tweet)

https://codebeautify.org/jsonviewer





Quick, easy, real-time business insights

Atlas Charts makes it easy to create dashboards with multiple charts in just a few clicks.

Loading instance


MongoDB.

Hi Roger! Welcome to Atlas Charts

Charts is the best way to create visualizations of your data.


- ✓ Zero setup Build a chart from any collection in your project
- ✓ Create, share and collaborate on charts and dashboards
- ✓ Embed charts and dashboards into applications
- Completely free to get started and no user-based pricing


Start





CONFIGURACIÓN MongoDB.

Where would you like to start?











> Dudas





01MBID

Roger

roger.clotet@professor.universidadviu.com

Gracias

